Milepæl 3: Quantile forecast med TCN

Mål: Utvide point-forecast TCN-en til en uncertainty-aware kvantilmodell som predikerer flere kvantiler for de neste 7 dagene, slik at modellen kan brukes både til probabilistisk forecasting og til restocking-beslutninger under usikkerhet.

Bygg:

- En early-stopping-hjelpemetode som stopper modellen etter 10 epoker uten forbedring
- Endre outputlaget slik at modellen predikerer kvantilene 0.1, 0.5 og 0.9 for hver av de 7 dagene i forecast-horisonten (outputlaget Y)
- Implementere pinball-loss for trening av kvantilprognoser
- Trene modellen på treningssettet og evaluere på test- og valideringssettet
- Generere kvantilprediksjoner på testsettet
- Evaluere modellen med pinball loss og coverage
- Knytte kvantilprognosen til inventory simulation policy, f.eks. ved å bruke en kvantil som order-up-to-grunnlag
- Sammenligne kvantilmodellen med point forecast TCN-modellen og baseline-policyene

Ønskelig output:

- En fungerende kvantil-TCN med korrekt input- og output-shape
- Trening som faktisk kjører med pinball loss
- Kvantilprediksjoner for testsettet
- Testresultater for pinball loss og coverage
- En første sammenligning mellom point forecast og quantile forecast i inventory simulation
- En første vurdering av om uncertainty-aware forecasting gir bedre decision performance enn point forecasting

Resultat:

```
jakob@Jakobs-MacBook-Air-2 project % /usr/bin/python3 /Users/jakob/Desktop/2026/DAT255/project/src/train_quantile.py
X_train shape: torch.Size([1315, 1, 28])
y_train shape: torch.Size([1315, 7])
X_val shape: torch.Size([282, 1, 28])
y_val shape: torch.Size([282, 7])
X_test shape: torch.Size([282, 1, 28])
y_test shape: torch.Size([282, 7])
Device: cpu
Quantiles: (0.1, 0.5, 0.9)
Quantile output shape: (batch, 3, 7)

Point forecast TCN:
Epoch 1 | train_loss=0.8041 | val_loss=0.7338
Epoch 2 | train_loss=0.7820 | val_loss=0.7269
Epoch 3 | train_loss=0.7649 | val_loss=0.7416
Epoch 4 | train_loss=0.7747 | val_loss=0.7274
Epoch 5 | train_loss=0.7499 | val_loss=0.7241
Epoch 6 | train_loss=0.7627 | val_loss=0.7374
Epoch 7 | train_loss=0.7560 | val_loss=0.7365
Epoch 8 | train_loss=0.7433 | val_loss=0.7297
Epoch 9 | train_loss=0.7348 | val_loss=0.7357
Epoch 10 | train_loss=0.7308 | val_loss=0.7387
Epoch 11 | train_loss=0.7276 | val_loss=0.7383
Epoch 12 | train_loss=0.7150 | val_loss=0.7403
Epoch 13 | train_loss=0.7022 | val_loss=0.7471
Epoch 14 | train_loss=0.7044 | val_loss=0.7491
Epoch 15 | train_loss=0.6896 | val_loss=0.7471
Early stopping: ingen forbedring i val_loss de siste 10 epochene.
```

```
Quantile forecast TCN:
Epoch 1 | train_loss=0.2952 | val_loss=0.2323
Epoch 2 | train_loss=0.2578 | val_loss=0.2355
Epoch 3 | train_loss=0.2537 | val_loss=0.2357
Epoch 4 | train_loss=0.2601 | val_loss=0.2340
Epoch 5 | train_loss=0.2558 | val_loss=0.2368
Epoch 6 | train_loss=0.2496 | val_loss=0.2369
Epoch 7 | train_loss=0.2476 | val_loss=0.2355
Epoch 8 | train_loss=0.2461 | val_loss=0.2381
Epoch 9 | train_loss=0.2458 | val_loss=0.2384
Epoch 10 | train_loss=0.2427 | val_loss=0.2383
Epoch 11 | train_loss=0.2419 | val_loss=0.2376
Early stopping: ingen forbedring i val_loss de siste 10 epochene.

Oppsummering av trening:
Point TCN stoppet tidlig ved epoch 15 av maks 60.
Point TCN bruker beste valideringsmodell fra epoch 5/60 med val-loss 0.7241.
Quantile TCN stoppet tidlig ved epoch 11 av maks 60.
Quantile TCN bruker beste valideringsmodell fra epoch 1/60 med val-loss 0.2323.
```

```
Kontroll av output-shape:
Quantile test predictions shape: (282, 3, 7)
Forventet shape: (num_samples, 3, 7)
```

```
Forecast-metrics på testsett:
Baseline MAE: 0.9488
Point TCN MAE (rå): 0.7366
Point TCN MAE (avrundet): 0.7016
Quantile TCN pinball loss: 0.2309
Quantile TCN median MAE (rå): 0.7274
Quantile TCN median MAE (avrundet): 0.7077

Policy-MAE på testsett:
Quantile policy MAE (q=0.1 som order-up-to): 0.7082
Quantile policy MAE (q=0.5 som order-up-to): 0.7077
Quantile policy MAE (q=0.9 som order-up-to): 1.6054

Coverage på testsett:
Empirisk coverage for q=0.1: 0.082 (mål: 0.1)
Empirisk coverage for q=0.5: 0.508 (mål: 0.5)
Empirisk coverage for q=0.9: 0.879 (mål: 0.9)
Sentral 10-90% intervall coverage: 0.798

Første kvantilprediksjon for testsettet:
q0.1: [-0.061 -0.009 -0.035 -0.036 -0.047 -0.043 -0.037]
q0.5: [ 0.093  0.029  0.032  0.026  0.015  0.013 -0.027]
q0.9: [1.342 1.175 1.38  1.37  1.379 1.33  1.247]
Første faktisk target: [3 1 0 0 1 0 2]
```

```
Første kvantilprediksjon for testsettet:
q0.1: [-0.061 -0.009 -0.035 -0.036 -0.047 -0.043 -0.037]
q0.5: [ 0.093  0.029  0.032  0.026  0.015  0.013 -0.027]
q0.9: [1.342 1.175 1.38  1.37  1.379 1.33  1.247]
Første faktisk target: [3 1 0 0 1 0 2]

Inventory metrics på testsett:
Baseline total cost: 5673.00, stockout rate: 0.296, fill rate: 0.320
Point TCN total cost: 6777.00, stockout rate: 0.414, fill rate: 0.036

Quantile policy-sammenligning:
q=0.1 (aggressiv) total cost: 6990.00, stockout rate: 0.427, fill rate: 0.000
q=0.5 (balansert) total cost: 6973.00, stockout rate: 0.427, fill rate: 0.003
q=0.9 (konservativ) total cost: 3969.00, stockout rate: 0.064, fill rate: 0.857
jakob@Jakobs-MacBook-Air-2 project %
```

Forklaring av output og tolkning av resultat:

Hyperparametre:

- Early stopping implementert med patience = 10 etter revidering fra milepæl 2
- Kvantilene 0.1, 0.5 og 0.9
- Output-shape satt til (batch, 3, 7), altså kvantil for kvantil istedenfor dag for dag

Quantile-modellen kjørte som planlagt med korrekt shape, fungerende pinball loss, beregning av coverage og sammenligning av policies.

Hovedresultater:

1. Forecast:

Modell	Baseline	Point TCN	Quantile TCN
MAE (rå)	0.9488	0.7366	
Pinball loss			0.2309
Median MAE (rå)			0.7274

2. Coverage for kvantilene q

q = 0.1	q = 0.5	q = 0.9
0.082	0.508	0.879

- Empirisk 10-90% intervall coverage = 0.879 - 0.082 = 0.798

3. Inventory

	total cost	stockout	fill rate
Baseline	5673.00	0.296	0.320
Point TCN	6777.00	0.414	0.036
Quantile q = 0.1	6990.00	0.427	0.000
Quantile q = 0.5	6973.00	0.427	0.003
Quantile q = 0.9	3969.00	0.064	0.857

Hovedfunn:

- Point TCN er bedre enn baseline på forecast-feil
- Quantile TCN gir brukbar kalibrering (spesielt rundt q=0.5 og q=0.9)
- q=0.9 ga klart best inventory-resultater blant policyene

Det mest interessante funnet akkurat nå er at point TCN er litt bedre enn quantile-median på MAE, mens quantile-policyen er mye bedre på decision metrics.

Uncertainty-aware forecasting ser ut til å gi bedre decision performance enn point forecasting i denne første Milepæl 3-kjøringen.

- q = 0.1 og q = 0.5 ga nesten null fill rate og høy stockout rate, noe som viser at valg av kvantil er avgjørende for inventory-policyen.
- Coverage er ganske nær målene for q = 0.5 og q = 0.9, men q = 0.1 underdekker litt hvilket tyder på at modellen fortsatt undervurderer den lave halen noe
- q = 0.9 gir dårligere forecast-MAE som ren order-up-to-policy enn medianen, men mye bedre decision performance. Det viser at beste forecast-tall ikke nødvendigvis gir beste lagerbeslutning.